

Полуопределенное программирование

Вычислительный интеллект, Лекция 8

Сергей Савин

2026

Общая форма задачи полуопределённого программирования:

$$\begin{aligned} & \underset{\mathbf{x}}{\text{minimize}} && \mathbf{c}^\top \mathbf{x}, \\ & \text{subject to} && \begin{cases} \mathbf{G} + \sum_{i=1}^n \mathbf{F}_i x_i \succeq 0, \\ \mathbf{A}\mathbf{x} = \mathbf{b}. \end{cases} \end{aligned} \quad (1)$$

где $\mathbf{F}_i$ и $\mathbf{G}$ симметричны, а $\succeq 0$ означает положительную полуопределённость.

Ограничение $\mathbf{G} + \sum_{i=1}^n \mathbf{F}_i x_i \succeq 0$ называется *линейным матричным неравенством* или *ЛМН*.

SDP может содержать несколько ЛМН. Предположим, у вас есть:

$$\begin{cases} \mathbf{G} + \mathbf{F}x_1 \succeq 0 \\ \mathbf{H}x_2 \succeq 0 \end{cases} \quad (2)$$

Это эквивалентно:

$$\begin{bmatrix} \mathbf{G} + \mathbf{F}x_1 & \mathbf{0} \\ \mathbf{0} & \mathbf{H}x_2 \end{bmatrix} \succeq 0 \quad (3)$$

Симметричная блочно-диагональная матрица является положительно полуопределённой тогда и только тогда, когда каждый её блок является положительно полуопределённым.

СЛЕД ПРОИЗВЕДЕНИЯ МАТРИЦ

Рассмотрим матрицы $\mathbf{E} = [\mathbf{e}_1 \quad \dots \quad \mathbf{e}_n]$ и $\mathbf{X} = [\mathbf{x}_1 \quad \dots \quad \mathbf{x}_n]$. Их произведение можно записать как:

$$\mathbf{E}^\top \mathbf{X} = \begin{bmatrix} \mathbf{e}_1^\top \mathbf{x}_1 & \mathbf{e}_1^\top \mathbf{x}_2 & \dots \\ \mathbf{e}_2^\top \mathbf{x}_1 & \mathbf{e}_2^\top \mathbf{x}_2 & \dots \\ \dots & \dots & \dots \end{bmatrix} \quad (4)$$

Таким образом, след этого произведения задаётся формулой:

$$\text{tr}(\mathbf{E}^\top \mathbf{X}) = \mathbf{e}_1^\top \mathbf{x}_1 + \dots + \mathbf{e}_n^\top \mathbf{x}_n \quad (5)$$

Видно, что это эквивалентно поэлементному скалярному произведению. Это представляет собой *матричное скалярное произведение* (скалярное произведение Фробениуса):

$$\text{tr}(\mathbf{E}^\top \mathbf{X}) = \sum_{i,j} E_{ij} X_{ij} \quad (6)$$

Иногда удобнее использовать полуопределённые матрицы непосредственно в качестве переменных решения:

$$\begin{aligned} & \underset{\mathbf{X}}{\text{minimize}} && \text{tr}(\mathbf{E}^\top \mathbf{X}), \\ & \text{subject to} && \begin{cases} \text{tr}(\mathbf{A}_i^\top \mathbf{X}) = b_i, \\ \mathcal{L}(\mathbf{X}) \succeq \mathbf{D}, \\ \mathbf{X} \succeq 0 \end{cases} \end{aligned} \tag{7}$$

где $\mathcal{L}(\mathbf{X})$ — линейная функция от $\mathbf{X}$.

В целевой функции матрица $\mathbf{E}$ играет роль весов, аналогично вектору $\mathbf{f}$ в линейном функционале $\mathbf{f}^\top \mathbf{x}$.

НЕПРЕРЫВНОЕ НЕРАВЕНСТВО ЛЯПУНОВА КАК SDP/ЛМН (1)

В теории управления достаточным условием асимптотической устойчивости непрерывной ЛТИ-системы $\dot{\mathbf{x}} = \mathbf{A}\mathbf{x}$ является существование такой $\mathbf{P} \succ 0$, что:

$$\mathbf{A}^\top \mathbf{P} + \mathbf{P} \mathbf{A} \preceq -\mathbf{Q} \quad (8)$$

где $\mathbf{Q} \succ 0$ — константа. Это называется *критерием Ляпунова*. Его можно представить в виде SDP:

$$\begin{aligned} & \underset{\mathbf{P}}{\text{minimize}} && 0, \\ & \text{subject to} && \begin{cases} \mathbf{P} \succeq \epsilon \mathbf{I}, \\ \mathbf{A}^\top \mathbf{P} + \mathbf{P} \mathbf{A} + \mathbf{Q} \preceq 0. \end{cases} \end{aligned} \quad (9)$$

где ϵ — малая положительная константа.

НЕПРЕРЫВНОЕ УРАВНЕНИЕ ЛЯПУНОВА КАК SDP/ЛМН (2)

```
0 n = 7; A = randn(n, n) - 3*rand*eye(n);  
Q = eye(n); I = eye(n); epsilon = 0.001;  
2  
4 cvx_begin sdp  
   variable P(n, n) symmetric  
   minimize 0  
6   subject to  
      P >= epsilon*I;  
8      A'*P + P*A + Q <= 0;  
cvx_end  
10  
12 if strcmp(cvx_status, 'Solved')  
    [eig(A), eig(A*P + P*A' + Q), eig(P)]  
14 else  
    eig(A)  
end
```

ДИСКРЕТНОЕ УРАВНЕНИЕ ЛЯПУНОВА КАК SDP/ЛМН (1)

Дискретная ЛТИ-система $\mathbf{x}_{i+1} = \mathbf{A}\mathbf{x}_i$ является асимптотически устойчивой, если существует такое $\mathbf{P} \succ 0$, что:

$$\mathbf{A}^\top \mathbf{P} \mathbf{A} - \mathbf{P} \preceq -\mathbf{Q} \quad (10)$$

где $\mathbf{Q} \succ 0$ — константа. Это можно представить в виде SDP:

$$\begin{aligned} & \underset{\mathbf{P}}{\text{minimize}} && 0, \\ & \text{subject to} && \begin{cases} \mathbf{P} \succeq 0, \\ \mathbf{A}^\top \mathbf{P} \mathbf{A} - \mathbf{P} + \mathbf{Q} \preceq 0. \end{cases} \end{aligned} \quad (11)$$

ДИСКРЕТНОЕ УРАВНЕНИЕ ЛЯПУНОВА КАК SDP/ЛМН (2)

```
0 n = 7; A = 0.35*randn(n, n);  
Q = eye(n); I = eye(n); epsilon = 0.001;  
2  
4 cvx_begin sdp  
   variable P(n, n) symmetric  
   minimize 0  
6   subject to  
       P >= epsilon*I;  
8       A'*P*A - P + Q <= 0;  
cvx_end  
10  
12 if strcmp(cvx_status, 'Solved')  
    [abs(eig(A)), eig(A'*P*A - P), eig(P)]  
14 else  
    abs(eig(A))  
end
```

Дополнение Шура. Дана матрица $\mathbf{M}$

$$\mathbf{M} = \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{B}^\top & \mathbf{C} \end{bmatrix} \quad (12)$$

с $\mathbf{A} \succ 0$. Можно сделать следующее утверждение:

■ $\mathbf{M} \succ 0$ тогда и только тогда, когда $\mathbf{C} - \mathbf{B}^\top \mathbf{A}^{-1} \mathbf{B} \succ 0$

Если $\mathbf{C}$ имеет полный ранг, можно сделать следующее утверждение:

■ $\mathbf{M} \succ 0$ тогда и только тогда, когда $\mathbf{C} \succ 0$ и $\mathbf{A} - \mathbf{B} \mathbf{C}^{-1} \mathbf{B}^\top \succ 0$

Докажем, что SOCP является подмножеством SDP.

Аффинное коническое ограничение второго порядка (SOC) имеет вид:

$$\|\mathbf{Ax} + \mathbf{b}\| \leq \mathbf{c}^\top \mathbf{x} + d \quad (13)$$

где $\mathbf{c}^\top \mathbf{x} + d \geq 0$. Перепишем SOC как:

$(\mathbf{Ax} + \mathbf{b})^\top (\mathbf{Ax} + \mathbf{b}) = (\mathbf{c}^\top \mathbf{x} + d)^2$, и, предполагая $\mathbf{c}^\top \mathbf{x} + d > 0$, получим:

$$\frac{(\mathbf{Ax} + \mathbf{b})^\top (\mathbf{Ax} + \mathbf{b})}{\mathbf{c}^\top \mathbf{x} + d} \leq \mathbf{c}^\top \mathbf{x} + d \quad (14)$$

что эквивалентно:

$$-\frac{(\mathbf{Ax} + \mathbf{b})^\top (\mathbf{Ax} + \mathbf{b})}{-(\mathbf{c}^\top \mathbf{x} + d)} \leq \mathbf{c}^\top \mathbf{x} + d \quad (15)$$

Заметим, что $-\frac{(\mathbf{Ax}+\mathbf{b})^\top(\mathbf{Ax}+\mathbf{b})}{-(\mathbf{c}^\top\mathbf{x}+d)} \leq \mathbf{c}^\top\mathbf{x} + d$ эквивалентно:

$$-\frac{(\mathbf{Ax} + \mathbf{b})^\top(\mathbf{Ax} + \mathbf{b})}{(\mathbf{c}^\top\mathbf{x} + d)} + (\mathbf{c}^\top\mathbf{x} + d) \geq 0 \quad (16)$$

Используя дополнение Шура, перепишем это как:

$$\begin{bmatrix} (\mathbf{c}^\top\mathbf{x} + d) & (\mathbf{Ax} + \mathbf{b}) \\ (\mathbf{Ax} + \mathbf{b})^\top & (\mathbf{c}^\top\mathbf{x} + d) \end{bmatrix} \succeq 0 \quad (17)$$

что является ЛМН-ограничением.

Рассмотрим следующее ограничение, где $\mathbf{X} \succeq 0$:

$$\|\mathbf{X}\mathbf{v} + \mathbf{b}\| \leq \mathbf{c}^\top \mathbf{y} + d \quad (18)$$

Можем ли мы переписать его как ЛМН? Используя тот же процесс, что и ранее, получаем:

$$\begin{bmatrix} (\mathbf{c}^\top \mathbf{y} + d) & (\mathbf{X}\mathbf{v} + \mathbf{b}) \\ (\mathbf{X}\mathbf{v} + \mathbf{b})^\top & (\mathbf{c}^\top \mathbf{y} + d) \end{bmatrix} \succeq 0 \quad (19)$$

Итак, (18) является допустимым ограничением в SDP.

Рассмотрим задачу: минимизировать наибольшее собственное значение $\mathbf{A}$. Решение:

$$\begin{aligned} & \underset{t}{\text{minimize}} && t, \\ & \text{subject to} && \mathbf{A} \preceq t\mathbf{I} \end{aligned} \tag{20}$$

Доказательство. Если λ — собственное значение $\mathbf{A}$, то $\mathbf{A}\mathbf{v} = \lambda\mathbf{v}$, следовательно $(\mathbf{A} - t\mathbf{I})\mathbf{v} = (\lambda - t)\mathbf{v}$, то есть $\lambda - t$ является собственным значением $(\mathbf{A} - t\mathbf{I})$. Таким образом, если $(\mathbf{A} - t\mathbf{I})$ отрицательно полуопределена, то $\lambda - t \leq 0$ и $\lambda \leq t$. □

Implement both examples from page 2 of the LMI CVX documents: stanford.edu/class/ee363/notes/lmi-cvx.pdf.

- Introduction to Semidefinite Programming (SDP), Robert M. Freund <https://ocw.mit.edu/courses/15-084j-nonlinear-programming-spring-2004/>
- Semidefinite Programming, L. Vandenberghe and S. Boyd: https://stanford.edu/boyd/papers/pdf/semidef_prog.pdf.
Main page: <https://stanford.edu/boyd/papers/sdp.html>

Слайды доступны на Github:

github.com/SergeiSa/Convex-Optimization



Let

$$\mathbf{M} = \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{B}^\top & \mathbf{C} \end{bmatrix}, \quad \mathbf{A} = \mathbf{A}^\top \succ 0.$$

We prove:

$$\mathbf{M} \succ 0 \iff \mathbf{C} - \mathbf{B}^\top \mathbf{A}^{-1} \mathbf{B} \succ 0.$$

Consider the quadratic form:

$$f = \begin{bmatrix} \mathbf{x}^\top & \mathbf{y}^\top \end{bmatrix} \begin{bmatrix} \mathbf{A} & \mathbf{B} \\ \mathbf{B}^\top & \mathbf{C} \end{bmatrix} \begin{bmatrix} \mathbf{x} \\ \mathbf{y} \end{bmatrix} \quad (21)$$

$$= \mathbf{x}^\top \mathbf{A} \mathbf{x} + 2\mathbf{x}^\top \mathbf{B} \mathbf{y} + \mathbf{y}^\top \mathbf{C} \mathbf{y}. \quad (22)$$

Complete the square:

$$f = (\mathbf{x} + \mathbf{A}^{-1} \mathbf{B} \mathbf{y})^\top \mathbf{A} (\mathbf{x} + \mathbf{A}^{-1} \mathbf{B} \mathbf{y}) + \mathbf{y}^\top (\mathbf{C} - \mathbf{B}^\top \mathbf{A}^{-1} \mathbf{B}) \mathbf{y}.$$

$$f = (\mathbf{x} + \mathbf{A}^{-1}\mathbf{B}\mathbf{y})^\top \mathbf{A}(\mathbf{x} + \mathbf{A}^{-1}\mathbf{B}\mathbf{y}) + \mathbf{y}^\top (\mathbf{C} - \mathbf{B}^\top \mathbf{A}^{-1}\mathbf{B})\mathbf{y}.$$

($\Rightarrow$) Suppose $\mathbf{M} \succ 0$.

■ Let $\mathbf{y} = 0$:

$$f = \mathbf{x}^\top \mathbf{A}\mathbf{x} > 0 \Rightarrow \mathbf{A} \succ 0.$$

■ Let $\mathbf{x} = -\mathbf{A}^{-1}\mathbf{B}\mathbf{y}$:

$$\begin{aligned} f &= \mathbf{y}^\top (\mathbf{C} - \mathbf{B}^\top \mathbf{A}^{-1}\mathbf{B})\mathbf{y} > 0 \\ &\Rightarrow \mathbf{C} - \mathbf{B}^\top \mathbf{A}^{-1}\mathbf{B} \succ 0. \end{aligned}$$

($\Leftarrow$) Suppose

$$\mathbf{A} \succ 0, \quad \mathbf{C} - \mathbf{B}^\top \mathbf{A}^{-1}\mathbf{B} \succ 0.$$

Then both terms in f are positive for all $(\mathbf{x}, \mathbf{y}) \neq 0$, hence:

$$f > 0 \Rightarrow \mathbf{M} \succ 0.$$

Conclusion:

$$\mathbf{M} \succ 0 \iff \mathbf{A} \succ 0 \text{ and } \mathbf{C} - \mathbf{B}^\top \mathbf{A}^{-1}\mathbf{B} \succ 0.$$